ПРАКТИЧЕСКАЯ ЦЕННОСТЬ EDA

При проведении EDA получены ответы на вопросы, каждый из которых напрямую влияет на итоговое решение: можно ли использовать данные без дополнительной предобработки и какие участки всё же требуют внимания, какие лаги цены допустимы для прогноза и как строить валидацию, как цена связана с прогнозными признаками и календарём и в каком виде признаки подавать модели; как распределена целевая переменная и что делать с её экстремальными значениями.

Качество данных. Набор данных из 17 544 строк (период с 2024 по 2025 г.) не имеет пропусков и дубликатов. Переход на летнее/зимнее время учтён корректно. Имеющаяся аномалия – округлённые значения прогноза сальдо обмена с апреля по сентябрь 2024 (в июле-августе до 75% значений кратны 100 MWh).

Лаги и схема валидации. Ключевое решение: прогноз на сутки вперёд публикуется до полудня, поэтому минимальный доступный лаг цены – 24 часа (корреляция 0,78). Также рабочий лаг – 168 ч (корреляция 0,69). Недельная сезонность выражена сильнее, чем следует из средних по дням недели. ADF-тест говорит о стационарности, но уровень и разброс ряда заметно меняются между сезонами и годами: зима 2024/25 вдвое дороже зимы 2024, лето 2025 дешевле и спокойнее лета 2024, устойчивого тренда нет. Отсюда следствие: лаг-1 и лаги короче 24 часов недоступны – их включение даёт фиктивно отличное качество, которое рушится на реальном применении, а единственный случайный train/test-сплит даёт искажённую оценку, поэтому валидацию нужно строить по времени и проверять на разных периодах.

Формат признаков. Главный драйвер цены – не отдельные факторы, а остаточная нагрузка (спрос минус солнце, ветер и атом; Spearman 0,69). Отсюда прямые решения: строить нелинейные модели (деревья, бустинг) или вводить преобразования вместо линейной регрессии на сырых признаках; использовать взаимодействия «час × месяц», потому что суточный профиль цены меняется по сезонам; «U-образную» температуру и дискретные режимы атома не подавать в модель как линейные величины. Отдельно зафиксирован признак is_holiday: 624 часа праздников в будни стоят в среднем на 30 EUR/MWh дешевле обычных будней – без него модель систематически завышает цены на эти часы.

Экстремальные значения целевой переменной. 3,7% часов имеют отрицательную цену (солнечные полдни выходных: 86% таких часов — выходные и праздники), 1,8% — экстремальные пики свыше 300 EUR/MWh (зимние и июльские вечера с высоким спросом и импортом). Распределение цены скошено вправо (асимметрия 3,3), логарифм применить нельзя из-за отрицательных значений, поэтому для стабилизации при обучении подходит преобразование arcsinh. Такие часы нельзя обрезать: их нужно предсказывать, а метрику качества оценивать отдельно на хвостах (цена ≤ 0 и > 300 EUR/MWh), потому что именно там ошибка наиболее дорогостоящая.